

UNIVERSITÀ DEGLI STUDI DI PADOVA

DIPARTIMENTO DI INGEGNERIA DELL'INFORMAZIONE

UNIVERSITÀ DEGLI STUDI DI PADOVA
Dipartimento di Ingegneria dell'Informazione
Corso di Laurea in Ingegneria Informatica

Relazione per la prova finale

Calcolo della mediana con memoria limitata: studio e sperimentazione dell'algoritmo multi-pass di Munro e Paterson

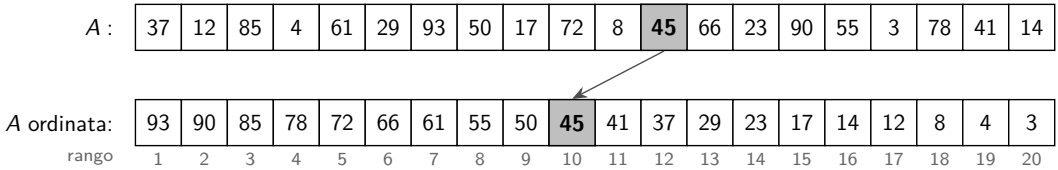
RELATORE
Prof. Andrea Pietracaprina

LAUREANDO
Alessandro Barbacetto

ANNO ACCADEMICO 2025/2026

Il problema della selezione

- **Input**: sequenza $A = (a_1, \ldots, a_N)$ di N elementi distinti di un dominio totalmente ordinato
- **Rango**: $a_{(k)}$ è il k-esimo elemento **più grande** di A
- **Selezione**: dato $1 \leq k \leq N$, trovare $a_{(k)}$ senza ordinare la sequenza
- **Mediana**: caso $k = \lceil N/2 \rceil$



$N = 20$, mediana: $k = \lceil 20/2 \rceil = 10$, quindi $a_{(10)} = 45$

Algoritmo SELECT

- **SELECT**: deterministico, *median of medians*
  - gruppi da 5 elementi e mediana di ogni gruppo
  - pivot x: la mediana delle mediane
  - Partizione attorno a x e ricorsione sulla parte contenente l'elemento cercato
- Tempo $O(N)$ anche nel caso peggiore, ma con tutto l'input in memoria

Come trovare la mediana quando la memoria disponibile è invece limitata?

Obiettivo della tesi

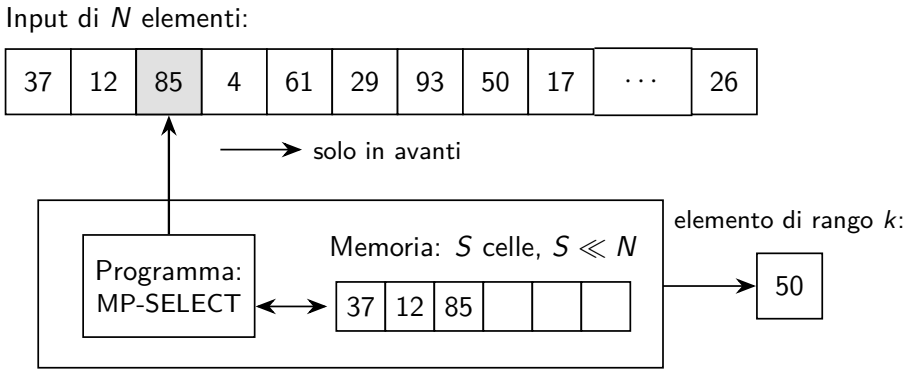
Studio dell'algoritmo multi-pass **MP-SELECT** di Munro e Paterson per la selezione con memoria limitata, e sua **analisi sperimentale**.

- S: celle di memoria disponibili, con $S \ll N$; ogni cella contiene un elemento
- P: numero di **passate**, cioè letture complete dell'input; è la misura di costo
- n: **candidati**, elementi compresi tra due filtri ($f_{\min}$ e $f_{\max}$), che possono ancora essere $a_{(k)}$
- n_p: numero di candidati **nella passata** $p \in [1, P]$, che diminuiscono di passata in passata

Trade-off qualitativo: meno memoria $S \implies$ più passate P

J. I. Munro, M. S. Paterson, *Selection and sorting with limited storage*, Theoretical Computer Science 12 (1980) 315–323.

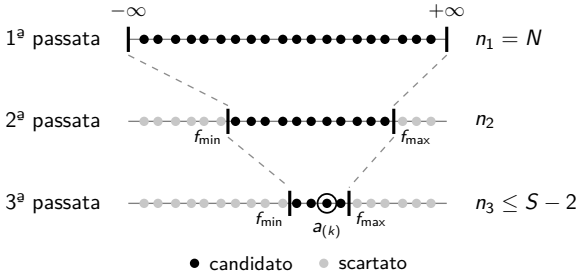
Il modello di calcolo: streaming



Modello di streaming (a più passate): l'input si legge solo in sequenza, dall'inizio alla fine, e può essere riletto più volte; in memoria si tengono al più S elementi

Modello RAM (classico): l'intero input è in memoria e si accede direttamente a qualsiasi elemento

L'algoritmo multi-pass



In ogni passata:

1. **Lettura**: si scorre l'input una volta
2. **Filtri**: si tengono solo i candidati, tra $f_{\min}$ e $f_{\max}$
3. **Campionamento**: i candidati, letti a blocchi ordinati, si dimezzano più volte (uno su due) e si fondono in un campione che sta in memoria
4. **Nuovi filtri**: dal campione, due filtri più vicini che racchiudono ancora $a_{(k)}$

Se il limite sui candidati è $\leq S - 2 \implies$ **un'ultima passata** permette di caricarli tutti in memoria e individuare l'elemento cercato.

Obiettivi dell'analisi sperimentale

Limite sui candidati $\bar{n}_p$: l'algoritmo non conosce esattamente n_p, infatti per contarlo servirebbe un'altra passata. Usa quindi un limite superiore $\bar{n}_p \geq n_p$, calcolato senza leggere i dati, per:

- garantire che il campione stia sempre nelle S celle
- decidere quando fermarsi: se $\bar{n}_p \leq S - 2 \Rightarrow$ **ultima passata**

Esperimenti su permutazioni casuali di $1, \ldots, N$, cercando la mediana $k = \lceil N/2 \rceil$:

1. confrontare il numero di passate P al variare di S e N
2. misurare quanto $\bar{n}_p$ sovrastimi n_p
3. osservare l'evoluzione del numero di candidati con l'aumentare delle passate

Implementazione

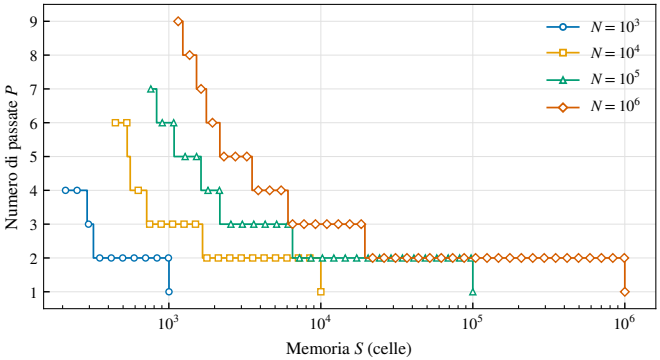
Algoritmo **MP-SELECT** implementato in **Python 3**

Risultati e grafici realizzati con *Matplotlib*



https://github.com/ill-barba/bsc-thesis-unipd-median-selection

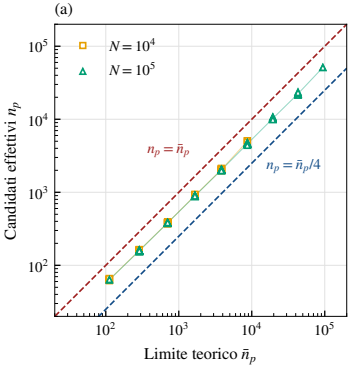
Trade-off tra memoria e passate

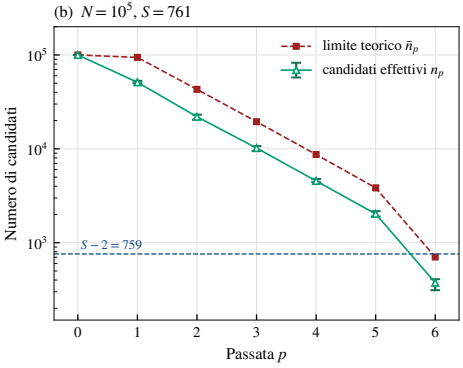


- Memoria per P passate: $S \sim N^{1/P}$
- Dipendenza logaritmica da N, con $S = \Omega(\log^2 N)$
- Lettura in entrambi i sensi: $S \to P$ e $P \to S$

Bound teorico: $\bar{n}_{p+1} = O\left(\frac{\bar{n}_p (\log \bar{n}_p)^2}{S}\right)$ **Fissata** S: $P \approx \frac{\log N}{\log S}$

Candidati effettivi e limite teorico



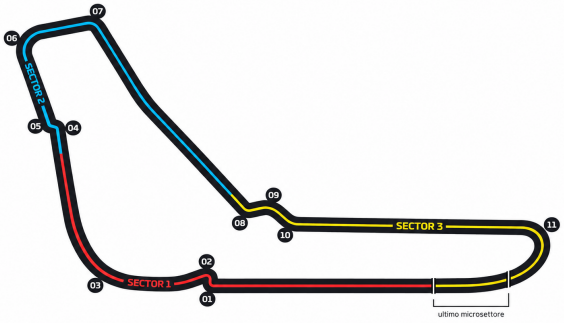


- $k = \lceil N/10 \rceil$ simile alla mediana; ranghi estremi come $k = 1$ hanno meno candidati
- Barre inizialmente vicine per effetto di compensazione della media
- "Rallentamento" dovuto alla guida di $\bar{n}_p$ nell'algoritmo

Limite: bound conservativo (circa il doppio dei candidati effettivi) può costare al più una passata in più del necessario.

Possibile sviluppo: euristica greedy *ad hoc* per tentare una terminazione anticipata.

Identificazione della finestra termica



Ultimo microsettore $\sim 3{,}8\,\mathrm{s}$

Giro di preparazione j:

$$T_j = (t_{j,1}, \ldots, t_{j,N_j}), \qquad k_j = \left\lceil \frac{N_j}{2} \right\rceil$$

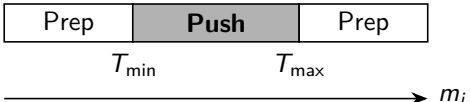
Mediana del giro:

$$m_j = \text{MP-SELECT}(T_j, k_j, S)$$

Primo giro nella finestra termica:

$$j^* = \min\{\, j \;:\; T_{\min} \le m_j \le T_{\max} \,\}$$

Graficamente:



Estensione a quattro pneumatici

Una mediana per ogni pneumatico:
$m_j^{FL},\ m_j^{FR},\ m_j^{RL},\ m_j^{RR}$

1. Conservativa: Push solo se tutte e quattro sono in finestra

$$T_{\min} \leq m_j^w \leq T_{\max} \qquad \forall\, w \in \{FL, FR, RL, RR\}$$

2. Media delle mediane: più permissiva

$$\overline{m}_j = \tfrac{1}{4}(m_j^{FL} + m_j^{FR} + m_j^{RL} + m_j^{RR}), \quad T_{\min} \leq \overline{m}_j \leq T_{\max}$$

3. Media pesata: trade-off, pesi diversi in base alle sollecitazioni degli pneumatici

$$\widetilde{m}_j = \alpha_{FL} m_j^{FL} + \alpha_{FR} m_j^{FR} + \alpha_{RL} m_j^{RL} + \alpha_{RR} m_j^{RR}$$
$$T_{\min} \leq \widetilde{m}_j \leq T_{\max}$$



Finestra termica per ogni mescola